

1 引言

大语言模型为机器人任务分解、情境推理和长时序规划提供了新的技术路径。通过结构化提示、受限动作接口或形式化约束，语言模型已经能够生成具有一定可执行性的机器人计划 [1, 2]。然而，室内移动机器人必须在障碍物、狭窄通道、观测不确定性和资源限制并存的环境中持续权衡任务推进与安全风险。语言模型可能忽略低频但严重的历史失败，也可能在相似场景中给出不一致建议。更重要的是，语义上合理的解释并不意味着动作满足机器人的物理与运行约束。因此，如何利用长期执行历史改善风险判断，同时避免历史不断累积造成的上下文膨胀，是语言模型进入真实机器人闭环前必须解决的问题。

已有语言 Agent 通过非参数记忆从交互历史中持续学习。Reflexion 将任务反馈转化为语言反思并存入情景记忆，ExpeL 从多次经历中提取可迁移的自然语言经验，Voyager 则维护可复用的具身技能库 [3, 4, 5]。这些工作证明了历史经验能够在不更新模型参数的情况下改善后续行为，但其目标主要是提高通用任务性能。若直接将完整机器人轨迹长期保留在提示上下文中，输入规模会随执行历史增长；若只存储高度抽象的经验总结，则又可能失去规则所依据的原始证据。此外，现有检索通常为单一决策者返回一组通用相似案例，没有考虑不同审议角色对历史证据的需求差异。例如，任务支持者更需要成功路径及有效缓解措施，而风险批评者应优先检查失败、高严重度和停止条件相关的案例。

与此互补，SELP、SAFER 和 RoboGuard 分别通过时序逻辑约束、多模型安全反馈以及形式化安全护栏限制语言模型产生的不安全计划 [2, 6, 7]。这些方法显著推进了 LLM 机器人规划的安全性，但历史风险知识通常不是其主要研究对象。尤其是，已有系统尚未同时解决三个相互关联的问题：如何在多个抽象层次压缩长期风险历史，如何保留高层规则到原始案例的可核查证据链，以及如何让承担不同职责的 Agent 获得不同而非同质化的历史证据。

本文提出一种面向室内移动机器人的风险经验感知多角色智能体框架。该框架以分层风险记忆组织长期交互经验，在控制上下文规模的同时保留抽象安全知识与原始案例之间的联系，并使机器人的经验安全边界能够随新证据持续更新。在此基础上，角色条件化检索根据 Task Advocate、Risk Critic 和 Safety Decision Agent 的职责提供差异化历史证据，以支持任务收益与安全风险之间的互补审议。各智能体仅生成结构化语义建议，最终动作仍由确定性约束优化与独立 Safety Guard 审核，从而将语言推理限制在可审计的安全执行边界内。

本文的主要贡献如下：

1. 一种风险经验感知的多角色智能体架构，通过 Task Advocate、Risk Critic 和 Safety Decision Agent 的互补审议，将历史风险证据融入具身任务决策，同时将语言推理与最终执行权限解耦。
2. 一种基于 Risk Memory Card 的分层安全风险记忆机制，将环境状态、任务目标、动作结果、失败原因和风险因素统一建模，并通过 L0 – L1 – L2 抽象支持上下文压缩、证据追踪和安全边界演化。
3. 一套系统实验评估方案，将通过多场景闭环仿真、组件消融和真实机器人实验，验证所提方法的任务性能、风险响应、决策效率以及长期交互下的安全边界更新能力。

本文关注高层语义动作选择，而非连续轨迹级安全保

证。风险与不确定性分数用于可解释的相对比较，不被解释为经过校准的碰撞概率。

References

- [1] I. Singh et al., “ProgPrompt: Generating Situated Robot Task Plans using Large Language Models,” ICRA, 2023.
- [2] Y. Wu et al., “SELP: Generating Safe and Efficient Task Plans for Robot Agents with Large Language Models,” ICRA, 2025.
- [3] N. Shinn et al., “Reflexion: Language Agents with Verbal Reinforcement Learning,” NeurIPS, 2023.
- [4] A. Zhao et al., “ExpeL: LLM Agents Are Experiential Learners,” AAAI, 2024.
- [5] G. Wang et al., “Voyager: An Open-Ended Embodied Agent with Large Language Models,” arXiv:2305.16291, 2023.
- [6] A. A. Khan et al., “Safety Aware Task Planning via Large Language Models in Robotics,” IROS, 2025.
- [7] Z. Ravichandran et al., “Safety Guardrails for LLM-Enabled Robots,” IEEE RA-L, 2026.