

1 引言

大语言模型能够将自然语言目标转化为机器人高层动作 [1, 2]。长期运行的移动机器人必须在推进任务的同时维护安全。历史动作、结果和风险记录可补充当前观测，用于风险判断并更新经验安全边界。要在长期部署中持续利用这些证据，系统需要紧凑且可追溯的风险记忆。

经验学习方法通过语言反思、自然语言经验或可复用技能利用交互历史 [3, 4, 5]，安全规划方法则以时序约束、安全反馈和形式化护栏限定机器人决策 [2, 6, 7]。将二者用于长期风险决策带来三个需求：在多个抽象层次压缩持续增长的历史，保留抽象知识到原始案例的证据链，并为不同审议角色检索与其职责相匹配的证据。这三个需求构成了本文的研究动机。

本文提出一种风险经验感知的多角色智能体框架。分层风险记忆压缩长期经验、保留证据链，并随新证据更新经验安全边界。角色条件化检索分别为 Task Advocate、Risk Critic 和 Safety Decision Agent 提供职责相关的历史信息。三个智能体仅生成结构化语义建议；确定性约束优化器与独立 Safety Guard 保留最终执行权限。

本文的主要贡献如下：

1. 我们提出一种风险经验感知的多角色智能体架构，为三个互补角色提供职责相关的历史证据，并将语言推理与执行权限解耦。
2. 我们构建一种基于 Risk Memory Card 的分层风险记忆，以 L0 – L1 – L2 表示环境、任务、动作结果、失败原因和风险因素，支持上下文压缩、证据追踪和安全边界演化。
3. 我们设计一套包含多场景闭环仿真、组件消融和真实机器人实验的评估方案，用于衡量任务性能、风险响应、决策效率和长期安全边界更新能力。

本文关注高层语义动作选择，不提供连续轨迹级安全保证。风险与不确定性分数用于相对比较，而非校准后的碰撞概率。

References

- [1] I. Singh et al., “ProgPrompt: Generating Situated Robot Task Plans using Large Language Models,” ICRA, 2023.
- [2] Y. Wu et al., “SELP: Generating Safe and Efficient Task Plans for Robot Agents with Large Language Models,” ICRA, 2025.
- [3] N. Shinn et al., “Reflexion: Language Agents with Verbal Reinforcement Learning,” NeurIPS, 2023.
- [4] A. Zhao et al., “ExpeL: LLM Agents Are Experiential Learners,” AAAI, 2024.
- [5] G. Wang et al., “Voyager: An Open-Ended Embodied Agent with Large Language Models,” arXiv:2305.16291, 2023.
- [6] A. A. Khan et al., “Safety Aware Task Planning via Large Language Models in Robotics,” IROS, 2025.
- [7] Z. Ravichandran et al., “Safety Guardrails for LLM-Enabled Robots,” IEEE RA-L, 2026.