

# Method

## Risk-aware Multi-agent Navigation with Hierarchical Memory

### Contents

|                                                             |    |
|-------------------------------------------------------------|----|
| 3 Method                                                    | 3  |
| 3.1 Problem Formulation . . . . .                           | 3  |
| 3.2 Framework Overview . . . . .                            | 4  |
| 3.3 Hierarchical Risk Memory . . . . .                      | 5  |
| 3.3.1 L0: 完整情景经验 . . . . .                                  | 5  |
| 3.3.2 L1: 风险记忆卡 . . . . .                                   | 5  |
| 3.3.3 L2: 可复用风险规则 . . . . .                                 | 6  |
| 3.3.4 可追溯性 . . . . .                                        | 6  |
| 3.4 Role-conditioned Risk-aware Retrieval . . . . .         | 6  |
| 3.4.1 可解释相关性评分 . . . . .                                    | 7  |
| 3.4.2 多样性与上下文预算 . . . . .                                   | 8  |
| 3.4.3 L2 规则匹配与冲突处理 . . . . .                                | 8  |
| 3.5 Multi-role Risk Deliberation . . . . .                  | 8  |
| 3.5.1 Task Advocate . . . . .                               | 9  |
| 3.5.2 Risk Critic . . . . .                                 | 9  |
| 3.5.3 Safety Decision Agent . . . . .                       | 9  |
| 3.5.4 结构化输出与失效关闭 . . . . .                                  | 9  |
| 3.6 Deterministic Constrained Action Selection . . . . .    | 10 |
| 3.6.1 硬约束与规则过滤 . . . . .                                    | 10 |
| 3.6.2 任务收益 . . . . .                                        | 10 |
| 3.6.3 场景与记忆联合风险 . . . . .                                   | 11 |
| 3.6.4 多源不确定性 . . . . .                                      | 12 |
| 3.6.5 约束选优与确定性回退 . . . . .                                  | 12 |
| 3.7 Safety Verification and Decision Traceability . . . . . | 13 |
| 3.7.1 三阶段动作谱系 . . . . .                                     | 13 |
| 3.7.2 Safety Guard 复核 . . . . .                             | 13 |
| 3.7.3 决策轨迹 . . . . .                                        | 14 |
| 3.7.4 验证边界 . . . . .                                        | 14 |
| 3.8 End-to-end Decision Algorithm . . . . .                 | 14 |
| 3.9 Implementation and Current Scope . . . . .              | 16 |
| 3.9.1 Software Architecture . . . . .                       | 16 |
| 3.9.2 Model Interface and Reproducibility . . . . .         | 16 |

---

|                                                     |    |
|-----------------------------------------------------|----|
| 3.9.3 Verification and Simulation Support . . . . . | 17 |
| 3.9.4 Current Scope and Limitations . . . . .       | 17 |
| 3.9.5 Planned Evaluation . . . . .                  | 17 |

### 3 Method

中文论文初稿。本章严格对应当前代码版本 **0cd8ecf**。文中的任务收益、风险、不确定性权重及判定阈值均为未经数据校准的工程基线；风险和不确定性是用于动作排序与约束的相对分数，而非真实事件发生概率。

#### 3.1 Problem Formulation

本文研究具身机器人在环境风险、感知不确定性与有限历史经验共同存在时的安全 动作选择问题。在决策时刻  $t$ ，将机器人面对的场景表示为

$$x_t = (g_t, r_t, o_t, \mathcal{A}_t),$$

其中， $g_t$  表示任务目标， $r_t$  表示机器人自身状态， $o_t$  表示当前环境观测， $\mathcal{A}_t$  表示当前场景允许执行的候选动作集合。机器人状态包含机器人类型、几何尺寸和剩余电量；环境观测包含目标距离、通道宽度、障碍物检测结果、障碍物 距离以及观测置信度。

设  $\mathcal{A}$  为系统支持的全局离散动作词表：

$$\mathcal{A} = \{\text{move\_forward}, \text{turn\_left}, \text{turn\_right}, \text{slow\_down}, \text{observe\_again}, \text{ask\_human}, \text{safe\_stop}\}.$$

当前可用动作由场景给出，并满足  $\mathcal{A}_t \subseteq \mathcal{A}$ 。这种区分使系统 能够根据机器人能力或环境限制动态禁用部分动作。本文假设 **safe\_stop**  $\in \mathcal{A}_t$ ，以保证系统始终存在保守回退动作。

为利用历史交互中的风险证据，系统维护分层风险记忆

$$\mathcal{M}_t = (\mathcal{M}_t^{L0}, \mathcal{M}_t^{L1}, \mathcal{M}_t^{L2}),$$

其中  $\mathcal{M}_t^{L0}$  为完整情景经验， $\mathcal{M}_t^{L1}$  为压缩且可追溯的 风险记忆卡， $\mathcal{M}_t^{L2}$  为跨案例复用的风险规则。三个角色 Agent 基于 当前场景与角色相关证据形成审议结果

$$\mathcal{D}_t = (d_t^{\text{adv}}, d_t^{\text{cri}}, d_t^{\text{dec}}),$$

其中  $d_t^{\text{adv}}$ 、 $d_t^{\text{cri}}$  和  $d_t^{\text{dec}}$  分别表示 Task Advocate、Risk Critic 和 Safety Decision Agent 的结构化报告。Agent 的输出仅作为语义推理证据和模型建议，不直接获得动作执行权限。

在此基础上，系统先通过硬安全约束与命中的 L2 禁止规则构造可行动作集合  $\mathcal{A}_t^{\text{safe}}$ ，再定义同时满足风险与不确定性阈值的合格动作集合：

$$\mathcal{E}_t = \left\{ a \in \mathcal{A}_t^{\text{safe}} \mid R(a \mid x_t, \mathcal{M}_t) \leq \tau_R, Q(a \mid x_t, \mathcal{M}_t, \mathcal{D}_t) \leq \tau_Q \right\}.$$

其中， $R(\cdot)$  和  $Q(\cdot)$  分别为相对风险分数与相对不确定性分数， $\tau_R$  和  $\tau_Q$  为对应上限。二者用于确定性约束与动作排序，并不表示真实 事件概率。系统在合格动作中最大化任务收益：

$$a_t^* = \begin{cases} \arg \max_{a \in \mathcal{E}_t} U_{\text{task}}(a \mid x_t), & \mathcal{E}_t \neq \emptyset, \\ \text{safe\_stop}, & \mathcal{E}_t = \emptyset. \end{cases}$$


最后，独立 Safety Guard  $G$  对优化动作进行执行前复核，得到唯一允许传递给未来 机器人执行接口的批准动作

$$a_t^{\text{app}} = G(x_t, a_t^*).$$

因此，本文的目标不是让大语言模型直接控制机器人，而是在历史风险证据与多角色推理的辅助下，由确定性约束优化器和独立安全守卫共同完成安全动作选择。

### 3.2 Framework Overview

所提出框架将语义风险推理与确定性安全约束分离。语言模型负责结合场景、历史风险证据与角色职责形成结构化建议；规则冲突门控、约束优化器和 Safety Guard 则负责对建议进行确定性筛选与执行前验证。因此，任一 Agent 的生成结果都不能直接成为机器人控制指令。框架的整体数据流可概括为：



具体而言，系统按以下六个阶段运行。

1. **场景结构化。** 系统读取任务目标、机器人状态、环境观测以及当前可用动作，并将其编码为统一场景表示  $x_t$ 。该表示是记忆检索、规则匹配、Agent 推理和确定性验证所共享的事实基础。
2. **分角色记忆检索与规则匹配。** 系统分别为 Advocate、Critic 和 Decision 构造受 Token 预算约束的 L1 风险证据包，并从 L2 规则库中检索满足当前场景条件的风险规则。角色相关的检索结果允许不同 Agent 关注任务收益、失败模式或决策证据，而 L2 规则提供可显式检查的行为约束。
3. **规则冲突门控。** 在调用语言模型之前，系统首先检查命中的 L2 规则是否给出相容的安全建议。若规则之间没有共同的安全动作，系统绕过全部 Agent 推理，确定性地产生 **safe\_stop**，标记需要人工复核，并将该动作交给 Safety Guard。该旁路阻止矛盾规则继续传播到生成式决策阶段。
4. **多角色风险审议。** 在不存在规则冲突时，Task Advocate 与 Risk Critic 分别从任务推进和风险质疑角度生成结构化报告；随后 Safety Decision Agent 综合场景事实、双方报告、角色化 L1 证据及命中的 L2 规则，输出模型建议  $a_t^{\text{LLM}}$ 。两份前置报告在逻辑上相互独立，当前实现按顺序调用。
5. **确定性约束动作选择。** 优化器不直接接受模型建议作为最终动作，而是在当前可用动作集合上执行硬约束过滤，并综合任务收益、场景与记忆风险以及多源不确定性进行约束选优。若不存在满足条件的候选动作，系统回退到 **safe\_stop**。

6. 安全复核与轨迹记录。Safety Guard 根据执行时硬规则复核优化动作，并输出 最终批准动作  $a_t^{\text{app}}$ 。系统同时保留角色化证据包、命中规则及其匹配原因、三角色报告、模型建议、优化评分、Guard 结果以及缓存和 Token 用量，形成 可审计的完整决策轨迹。

由此，正常路径为“检索—审议—约束选优—安全复核”，规则冲突路径则为“冲突检测—保守停止—安全复核”。第 3.3 – 3.7 节将分别给出各模块的记忆表示、检索机制、角色 职责、优化目标与安全验证方法。

### 3.3 Hierarchical Risk Memory

为缓解完整交互历史随任务持续增长而带来的上下文膨胀，系统采用由案例到规则逐级 抽象的三层风险记忆：L0 保存可复查的完整情景经验，L1 将相关经验压缩为适合输入 Agent 的风险记忆卡，L2 则表示跨案例复用的条件化风险规则。三层记忆可写为

$$\mathcal{M}_t = (\mathcal{M}_t^{L0}, \mathcal{M}_t^{L1}, \mathcal{M}_t^{L2}),$$

其中，信息密度和复用范围从 L0 到 L2 逐步提高，而实例细节逐步减少。为避免抽象 过程切断证据来源，每一层均保留指向下层记忆的稳定标识。

#### 3.3.1 L0: 完整情景经验

L0 是持久化的案例层，保存一次历史交互的场景条件、实际动作和观测结果。第  $i$  条经验表示为

$$e_i = (g_i, r_i, o_i, a_i, y_i, z_i, d_i, l_i),$$

其中， $g_i$  为任务目标， $r_i$  为机器人状态， $o_i$  为环境观测， $a_i$  为实际动作， $y_i$  为结果及其状态， $z_i$  为风险类型、严重度和失败原因， $d_i$  为当时的决策， $l_i$  为由该案例得到的安全教训。每条记录具有唯一 **experience\_id**，结果状态必须 属于 success、failure 或 aborted，风险严重度限定为 1 至 5。加载时，系统检查 必需字段、标识唯一性和取值范围，从而阻止结构不完整的案例进入检索过程。

L0 同时保留成功、失败和中止案例。失败案例提供危险动作与失败模式之间的反例证据；成功案例则记录风险被何种观测、减速或停止策略有效缓解。L0 的目标是保留可供复查 和重新压缩的事实基础，而不是在每次推理时将全部历史直接拼接进提示词。

#### 3.3.2 L1: 风险记忆卡

为降低长上下文中的冗余，系统仅对检索到的 L0 候选经验动态构造 L1 风险记忆卡：

$$m_i = C(e_i, s_i^{(k)}, k),$$

其中， $C(\cdot)$  为确定性的结构化压缩函数， $s_i^{(k)}$  为经验  $e_i$  面向角色  $k \in \{\text{adv}, \text{cri}, \text{dec}\}$  的检索得分。该过程不是由语言模型 自由摘要，而是通过固定字段映射生成，因此相同输入能够得到可重复的卡片结构。

每张 L1 卡包含以下信息：

- 身份与来源：模式版本、memory\_id、原始 experience\_id 及 source；
  - 适用上下文：机器人类型、任务目标、通行余量、障碍物状态与距离、观测置信度
- 和剩余电量；

- **风险证据**：风险类型、严重度、执行动作、结果、失败原因、缓解措施与停止条件；
- **质量信息**：支持次数、成功/失败/中止统计、可靠性以及最近验证时间；
- **检索元数据**：目标角色、总分、分项得分、匹配原因、冗余惩罚和检索器版本。

因此，L1 是面向推理上下文的**有损但可追溯压缩**：它删除 L0 中与当前风险判断 关系较弱的重复表示，但保留“触发条件—动作—结果—风险—缓解措施”的因果证据链。L1 不替代 L0；当卡片结论需要审计或重新解释时，仍可利用 **experience\_id** 返回原始 案例。当前实现按请求即时生成 L1 卡，而不是将其作为独立文件长期存储。

相较于直接拼接完整历史，L1 卡片有三个作用：第一，在固定上下文预算内提供更多 有效证据；第二，将环境、动作、结果与风险显式绑定；第三，保留成功缓解案例和 失败案例，使系统既能学习“什么不能做”，也能学习“在什么条件下可以安全执行”。

### 3.3.3 L2：可复用风险规则

L2 是持久化的规则层，用于将多个 L1 案例中反复出现的条件—风险—动作关系表示为 可执行检查的条件规则：

$$q_j = (c_j, A_j^+, A_j^-, B_j, S_j, n_j, \rho_j, h_j),$$

其中  $c_j$  为触发条件， $A_j^+$  为推荐动作集合， $A_j^-$  为禁止动作集合， $B_j$  为缓解措施， $S_j$  为来源风险卡 ID 集合， $n_j$  为支持、成功和失败统计， $\rho_j$  为规则置信度， $h_j$  为规则状态。规则状态属于 active、candidate 或 retired；在线决策阶段只匹配 active 规则。

与自然语言经验教训不同， $c_j$  被编码为可由程序直接判断的结构化阈值。例如，**maximum\_clearance\_m** 和 **maximum\_observation\_confidence** 分别约束通行总余量和观测 置信度。只有全部触发条件均满足时规则才被命中，系统同时返回实际数值与阈值构成的 **match\_reasons**。命中规则按照置信度及来源案例数量排序，后续冲突门控再检查其推荐 动作是否存在共同且未被禁止的安全选项。

当前实现中的 L1 卡由 L0 动态构造，L2 规则由人工归纳与验证后写入规则库。自动聚类、自动规则归纳、长期置信度更新以及规则退役机制尚未实现，因此不作为 本章已完成贡献进行表述。

### 3.3.4 可追溯性

系统通过稳定 ID 建立由规则到案例的证据链：

$$q_j \xrightarrow{\text{source\_memory\_ids}} \{m_i\}_{i \in S_j} \xrightarrow{\text{experience\_id}} \{e_i\}_{i \in S_j}.$$

L1 卡片还保存模式版本、来源描述以及检索器版本，使后续实验能够区分记忆内容变化 与检索策略变化。三个 Agent 通过 **cited\_experience\_ids** 和 **cited\_rule\_ids** 显式 声明其使用的历史证据；程序在接受模型输出前，将这些引用与实际输入给该 Agent 的 经验和规则 ID 集合进行比对。若输出包含不存在或未提供的 ID，则报告验证失败， 机器人不得依据该输出执行动作。该机制只能证明“引用对象存在且曾被提供”，不能单独 证明模型对证据的解释必然正确；因此，引用校验仍需与后续确定性优化及 Safety Guard 共同使用。

## 3.4 Role-conditioned Risk-aware Retrieval

给定当前场景  $x_t$ ，检索器不是为三个角色返回同一组历史案例，而是根据各角色在 审议过程中的职责分别构造证据包。对角色  $k \in \{\text{adv}, \text{cri}, \text{dec}\}$ ，该过程输出

$$\mathcal{B}_t^{(k)} = \text{Retrieve}_k(x_t, \mathcal{M}^{L0}; K, B_k),$$

其中,  $K$  为最多返回的 L1 卡片数量,  $B_k$  为角色提示词的记忆 Token 预算。检索过程依次执行候选过滤、角色化精排、多样性选择和预算装包, 所有得分及匹配原因 均随证据包返回。

### 3.4.1 可解释相关性评分

对当前场景  $x_t$ 、候选经验  $e_i$  和角色  $k$ , 系统计算

$$S_k(e_i, x_t) = w_{k,s}S_{sim} + w_{k,v}S_{sev} + w_{k,r}S_{rel} + w_{k,t}S_{rec} + w_{k,f}S_{role}.$$

$S_{sim}$  表示场景相似度,  $S_{sev}$  表示风险严重度,  $S_{rel}$  表示经验可靠性,  $S_{rec}$  表示时效性,  $S_{role}$  表示经验与 Agent 职责的适配程度。各项均归一化到  $[0, 1]$ , 且每个角色的权重之和为 1。

场景相似度由六类可解释匹配组成: 机器人类型相同记 1.5 分, 障碍物检测状态相同记 1.0 分, 任务目标相同记 1.0 分; 通行余量差不超过 0.05 m 或 0.15 m 时分别记 3.0 或 1.5 分; 障碍物距离差不超过 0.30 m 或 1.0 m 时分别记 2.0 或 0.75 分; 观测置信度差不超过 0.15 时记 1.5 分。原始相似度最高为 10 分, 并通过

$$S_{sim} = \min\left(\frac{S_{sim}^{raw}}{10}, 1\right)$$

归一化。 $S_{sim} = 0$  的经验不会进入后续候选池。风险严重度按照  $S_{sev} = z_i^{sev}/5$  归一化。若经验显式提供质量置信度, 系统直接将其截断到  $[0, 1]$ ; 若仅提供成功与失败统计, 则采用带 Beta(1, 1) 先验的后验均值

$$S_{rel} = \frac{n_i^{succ} + 1}{n_i^{succ} + n_i^{fail} + 2}.$$

当上述信息均不存在时, 系统根据 success、failure 和 aborted 状态分别使用 0.85、0.75 和 0.65 作为工程回退值。对于带有最近验证时间的经验, 时效性按照

$$S_{rec} = \exp\left(-\frac{\Delta t_i}{180}\right)$$

衰减, 其中  $\Delta t_i$  为距当前时间的天数; 缺少有效时间戳时取 0.5。上述取值是 当前原型中的显式工程设定, 并不被解释为经过统计校准的真实概率。

角色权重设置为:

| 角色 $k$   | $w_{k,s}$ | $w_{k,v}$ | $w_{k,r}$ | $w_{k,t}$ | $w_{k,f}$ |
|----------|-----------|-----------|-----------|-----------|-----------|
| Advocate | 0.35      | 0.05      | 0.20      | 0.05      | 0.35      |
| Critic   | 0.30      | 0.25      | 0.15      | 0.05      | 0.25      |
| Decision | 0.35      | 0.20      | 0.20      | 0.10      | 0.15      |

因此, Advocate 更重视与任务推进相关的可靠成功或缓解经验; Critic 更重视高严重度失败证据与停止案例; Decision 同时重视成功缓解和失败反例。具体地, Advocate 对成功案例的角色适配分为 1.0、对其他案例为 0.35; Critic 对 failure 或 aborted 案例赋 1.0, 对严重度不低于 4 或执行 **safe\_stop** 的案例赋 0.8, 其余为 0.4; Decision 对 success 或 failure 案例赋 0.9, 其余为 0.7。最终输出保留 **score\_breakdown** 和自然语言 **match\_reasons**。权重与角色适配值目前均为可审计的手工基线, 尚未通过训练数据学习或校准。

### 3.4.2 多样性与上下文预算

仅按  $S_k$  取前  $K$  个案例可能使相同风险类型和相同结果的重复案例占满上下文。因此，系统首先建立最多  $3K$  个候选的池，并采用贪心 MMR 式准则逐个选择：

$$e^* = \arg \max_{e_i \in \mathcal{C}} \left[ S_k(e_i, x_t) - \lambda \max_{e_j \in \mathcal{B}_t^{(k)}} D(e_i, e_j) \right],$$

其中  $\lambda = 0.15$ 。若两条经验风险类型相同，冗余度  $D$  增加 0.5；结果状态相同 增加 0.25；安全教训完全相同再增加 0.25。因此  $D \in [0, 1]$ 。该机制保留高相关 证据，同时鼓励成功案例、失败反例和不同风险模式共同进入角色证据包。

完成多样性选择后，系统将候选经验依次转换为 L1 卡片，并估算其 JSON 序列化后的 Token 成本。当前离线估计器将每个中日韩字符计为一个 Token，并将其他非空白字符 按每四个字符约一个 Token 估算。证据包必须同时满足

$$|\mathcal{B}_t^{(k)}| \leq K, \quad \sum_{m_i \in \mathcal{B}_t^{(k)}} \hat{T}(m_i) \leq B_k,$$

其中  $\hat{T}$  为近似 Token 数。若加入某张完整卡片会超过预算，系统跳过该卡，而不是截断其内部证据字段。当前三种角色均设置  $K = 3$ 、 $B_k = 1800$ 。预算值控制的 只是风险记忆部分，而不是整个 API 请求的精确 Token 数；其主要用途是在长历史条件下 提供确定、可测试的上下文上限。

### 3.4.3 L2 规则匹配与冲突处理

L2 检索不复用 L1 的加权排名，而是采用确定性条件匹配。对于每条 active 规则  $q_j$ ，仅当场景满足其全部触发条件  $c_j$  时，才将其加入命中集合

$$\mathcal{Q}_t = \{q_j \in \mathcal{M}^{L2} \mid c_j(x_t) = 1\}.$$

匹配器同时返回构成判断的实际场景数值和规则阈值，并按照规则置信度和来源记忆数量 降序排列结果。令  $A_j^+$  和  $A_j^-$  分别为规则  $q_j$  的推荐与禁止动作集合，则 多规则共同允许的候选集合为

$$\mathcal{U}_t = \left( \mathcal{A}_t \cap \bigcap_{q_j \in \mathcal{Q}_t} A_j^+ \right) \setminus \bigcup_{q_j \in \mathcal{Q}_t} A_j^-.$$

当没有规则命中时，系统继续正常的三角色决策流程；当  $\mathcal{U}_t \neq \emptyset$  时，规则被标记为可协调，命中规则及其推荐动作作为显式证据进入后续流程；当  $\mathcal{U}_t = \emptyset$  时，系统将其判定为规则冲突，记录所有冲突规则 ID 和 各自建议，跳过三 Agent 的 API 调用并执行保守回退。回退顺序为 **safe\_stop**、**ask\_human**、**observe\_again** 中第一个当前可用的动作；在本文假设 **safe\_stop** 始终 可用的动作空间下，冲突结果即为 **safe\_stop**。这种设计使规则矛盾显式暴露给人工 审查，而不要求语言模型临时解释或消解相互冲突的安全约束。

## 3.5 Multi-role Risk Deliberation

多角色审议的目标不是通过增加模型数量进行多数投票，而是将任务推进、风险反驳和 证据仲裁分解为具有不同信息需求的三个职责。当前实现使用同一个底层语言模型，通过 三组独立系统提



示词和三次结构化 API 调用实例化三个角色。给定场景  $x_t$ 、角色化 证据包  $\mathcal{B}_t^{(k)}$  和命中规则  $\mathcal{Q}_t$ ，审议过程表示为

$$\begin{aligned} d_t^{adv} &= F_{adv} \left( x_t, \mathcal{B}_t^{(adv)}, \mathcal{Q}_t \right), \\ d_t^{cri} &= F_{cri} \left( x_t, \mathcal{B}_t^{(cri)}, \mathcal{Q}_t \right), \\ d_t^{dec} &= F_{dec} \left( x_t, d_t^{adv}, d_t^{cri}, \mathcal{B}_t^{(dec)}, \mathcal{Q}_t \right). \end{aligned}$$

其中， $F_{adv}$ 、 $F_{cri}$  和  $F_{dec}$  分别表示受角色提示约束的语言模型调用。Advocate 和 Critic 均直接基于原始场景独立生成报告，互不读取对方输出；Decision 在两份前置报告均通过验证后再进行仲裁。因此，该拓扑保留了任务支持观点与风险反例之间的显式差异，同时为最终建议提供单一、可追踪的综合入口。

### 3.5.1 Task Advocate

Task Advocate 在不忽略风险的前提下寻找任务可行性。其输出  $d_t^{adv}$  包含推荐类型、候选动作、预期任务收益、显式假设、已识别风险、缓解措施、使用的经验与规则 ID，以及自报置信度。该角色必须从  $\mathcal{A}_t$  中选择候选动作；当信息不足或风险过高时，可以选择 **observe\_again**、**ask\_human** 或 **safe\_stop**，而不是被要求始终推动任务执行。

Advocate 的作用是形成“在何种假设和缓解措施下仍可推进”的正向论证。其输出不是安全证明：假设可能不成立，自报置信度也不是经过校准的成功概率，因此后续 Critic、Decision 和确定性约束模块仍需独立审查该建议。

### 3.5.2 Risk Critic

Risk Critic 主动搜索碰撞、卡死、失控、任务失败和需要人工介入等失效模式。对于每个风险，其报告  $d_t^{cri}$  给出风险名称、描述、模型估计的发生可能性、1 至 5 级严重度、场景证据与缓解措施，并进一步列出缺失信息、停止条件、建议动作、证据引用和自报置信度。风险证据只能来自输入场景或提供的历史记忆，不允许虚构传感器观测。

Critic 不接收  $d_t^{adv}$ ，从而避免直接围绕 Advocate 的措辞进行迎合式修正。同时，Critic 也不被设定为无条件拒绝任务：当风险可以通过补充观测、减速或改变计划缓解时，应输出相应措施。其 **probability** 字段表示模型用于比较风险的主观评分，当前尚未通过真实事故频率进行概率校准。

### 3.5.3 Safety Decision Agent

Safety Decision Agent 接收原始场景、两份前置报告、Decision 专用 L1 证据包及命中的 L2 规则。其职责是基于证据完成仲裁，而不是对 Advocate 与 Critic 的动作进行简单投票。提示词规定原始场景事实优先于 Agent 推断，并要求区分已观察事实、推断结论与建议阈值；未解决的高严重度风险不能被笼统理由忽略。

输出  $d_t^{dec}$  包含决策类别、所选动作、理由、带来源类型的支持证据、已接受风险、未解决风险、仍需获取的信息、引用 ID 和自报置信度。支持证据的来源标签被限制为 **scenario**、**experience**、**rule**、**advocate** 或 **critic**；决策类别被限制为 **execute**、**revise\_plan**、**observe\_again**、**ask\_human**、**reject** 或 **safe\_stop**。由此得到的所选动作记为模型建议  $a_t^{\text{LLM}}$ ，它仍需经过第 3.6 节的确定性约束选优。

### 3.5.4 结构化输出与失效关闭

每次模型调用只接受一个 JSON 对象作为有效输出。系统对三份报告执行以下检查：

1. 语法检查：去除可选 JSON 代码围栏后进行严格解析，并要求顶层为对象；
2. 结构检查：确认各角色所需字段、列表和嵌套对象存在且类型正确；
3. 数值与枚举检查：检查置信度位于  $[0, 1]$ 、Critic 风险严重程度位于 1 至 5，并验证风险等级、Decision 决策类型和证据来源标签；
4. 动作授权检查：确认 Advocate、Critic 和 Decision 提出的动作均属于当前场景的  $\mathcal{A}_t$ ；
5. 引用完整性检查：确认 `cited_experience_ids` 和 `cited_rule_ids` 分别属于实际输入给该角色的经验和规则 ID 集合。

若任一调用发生网络错误、响应字段缺失、JSON 截断或解析失败，或者报告未通过上述验证，整个三角角色流程以错误状态结束，机器人不得执行该轮动作。该失效关闭策略防止不完整的上游报告继续进入 Decision 或优化器。需要注意的是，结构验证只能保证输出形式、动作权限和引用存在性，不能保证自然语言推理本身正确；这也是后续确定性约束选择与 Safety Guard 仍然必要的原因。

### 3.6 Deterministic Constrained Action Selection

三个 Agent 完成审议后，系统不直接执行  $a_t^{\text{LLM}}$ ，而是在有限动作集合  $\mathcal{A}_t$  上重新求解一个确定性约束选择问题。该模块以 Decision 角色的 L1 证据包、命中的 L2 规则及三份 Agent 报告作为辅助证据，对所有可用动作使用同一组显式函数进行评估。给定相同输入和参数，优化器始终产生相同结果。

#### 3.6.1 硬约束与规则过滤

优化器首先在数值评分之前构造硬约束可行集

$$\mathcal{A}_t^{\text{safe}} = \left\{ a \in \mathcal{A}_t \mid H(x_t, a) = 1 \wedge a \notin \bigcup_{q_j \in \mathcal{Q}_t} \mathcal{A}_j^- \right\}.$$

其中  $H(x_t, a)$  表示物理硬规则。对于移动动作 `move_forward`、`slow_down`、`turn_left` 和 `turn_right`，以下任一条件成立即令  $H(x_t, a) = 0$ ：检测到的障碍物距离不超过 0.30 m、观测置信度低于 0.50、电量不超过 10%，或通行总余量低于 0.10 m。非移动动作不会因这些移动风险被过滤，但仍必须属于  $\mathcal{A}_t$ ，并且不能出现在任何命中 L2 规则的禁止动作集合中。

硬约束不是可由高任务收益抵消的软惩罚。系统为每个动作记录 `emergency_obstacle_distance`、`battery_below_hard_limit` 或 `prohibited_by_l2_rule:<rule_id>` 等拒绝原因。只有保留在  $\mathcal{A}_t^{\text{safe}}$  中的动作才进入后续收益、风险和不确定性计算。

#### 3.6.2 任务收益

对于  $a \in \mathcal{A}_t^{\text{safe}}$ ，任务收益定义为

$$U_{\text{task}}(a) = 0.65P(a) - 0.20C_T(a) - 0.15C_E(a),$$

其中  $P(a)$  为任务进展， $C_T(a)$  为时间成本， $C_E(a)$  为能量成本。三个属性由以下显式动作配置表给出，均位于  $[0, 1]$ ：

| 动作                        | $P(a)$ | $C_T(a)$ | $C_E(a)$ |
|---------------------------|--------|----------|----------|
| move_forward              | 1.00   | 0.10     | 0.25     |
| slow_down                 | 0.65   | 0.30     | 0.15     |
| turn_left /<br>turn_right | 0.20   | 0.25     | 0.10     |
| observe_again             | 0.00   | 0.25     | 0.05     |
| ask_human                 | 0.00   | 0.80     | 0.00     |
| safe_stop                 | 0.00   | 1.00     | 0.00     |

系统同时输出各属性对最终收益的贡献。表中参数是便于复核的手工工程基线，尚未使用真实导航时间、能耗或任务完成率进行拟合。

### 3.6.3 场景与记忆联合风险

令  $\text{clip}(u) = \min(1, \max(0, u))$ ，通行总余量为  $c_t = w_t^{\text{corridor}} - w_t^{\text{robot}}$ 。系统从当前场景计算四项风险因子：

$$\begin{aligned}
 R_{clr} &= \text{clip}\left(\frac{0.40 - c_t}{0.40}\right), \\
 R_{obs} &= \mathbb{K}[o_t^{\text{det}}] \text{clip}\left(\frac{1.50 - d_t^{\text{obs}}}{1.50}\right), \\
 R_{per} &= \text{clip}(1 - p_t^{\text{obs}}), \\
 R_{bat} &= \text{clip}\left(1 - \frac{b_t}{100}\right).
 \end{aligned}$$

其中， $o_t^{\text{det}}$  表示是否检测到障碍物， $d_t^{\text{obs}}$  为障碍物距离， $p_t^{\text{obs}}$  为观测置信度， $b_t$  为剩余电量。若相应数值缺失，除“明确未检测到障碍物”对应  $R_{obs} = 0$  外，当前工程实现对缺失风险因子使用 0.5。上下文风险为

$$R_{ctx} = 0.35R_{clr} + 0.30R_{obs} + 0.25R_{per} + 0.10R_{bat}.$$

考虑不同动作对环境风险的暴露程度  $\gamma_a$ ，得到

$$R_{scene}(a) = \gamma_a R_{ctx}.$$

其中 move\_forward、slow\_down、turn\_left/right、observe\_again、ask\_human 和 safe\_stop 的  $\gamma_a$  分别为 1.00、0.55、0.65、0.08、0.02 和 0.00。

历史风险只使用记录了相同动作的 Decision 角色 L1 卡片。对记忆  $m_i$ ，其证据权重与相似度和可靠性成正比，证据风险由严重度与结果因子共同确定：

$$\pi_i = S_{sim}(m_i, x_t) S_{rel}(m_i), \quad h_i = S_{sev}(m_i) F_{out}(m_i),$$

$$R_{memory}(a) = \frac{\sum_{i:a_i=a} \pi_i h_i}{\sum_{i:a_i=a} \pi_i}.$$

结果因子  $F_{out}$  对 failure、aborted 和 success 分别取 1.0、0.8 和 0.05，未知状态取 0.5。成功经验仍保留一个较小的残余风险，而不会被解释为绝对安全。场景风险与记忆风险的组合为

$$R(a) = 0.70R_{scene}(a) + 0.30R_{memory}(a).$$

当不存在同动作历史证据时，系统不虚构记忆风险，而是令  $R(a) = R_{scene}(a)$ ，并将实际来源权重记录为 scene 1.0、memory 0.0。 $R(a)$  是用于动作间比较的相对风险分数，不是事故发生概率。

### 3.6.4 多源不确定性

动作不确定性综合感知、记忆覆盖和 Agent 报告一致性：

$$Q(a) = 0.45Q_{obs}(a) + 0.30Q_{mem}(a) + 0.25Q_{agent}(a).$$

观测不确定性为

$$Q_{obs}(a) = (1 - p_t^{obs})\eta_a,$$

其中缺少观测置信度时令原始不确定性为 1。动作暴露系数  $\eta_a$  对 move\_forward、slow\_down、turn\_left/right、observe\_again、ask\_human 和 safe\_stop 分别取 1.00、0.70、0.80、0.10、0.05 和 0.00。

记忆支持度及记忆不确定性定义为

$$L_a = \sum_{i:a_i=a} S_{sim}(m_i, x_t) S_{rel}(m_i),$$

$$Q_{mem}(a) = \left[ 1 - \text{clip} \left( \frac{L_a}{1.5} \right) \right] \kappa_a,$$

其中证据目标支持度为 1.5； $\kappa_a$  对 move\_forward、slow\_down、turn\_left/right、observe\_again、ask\_human 和 safe\_stop 分别取 1.00、0.80、0.70、0.10、0.10 和 0.05。因而，动作越依赖历史支持而同动作记忆越稀缺，其记忆不确定性越高。

Agent 分歧根据报告中可解析的首选标签及其自报置信度计算。令  $v_k$  为角色  $k$  的首选标签， $c_k \in [0, 1]$  为其置信度，则

$$Q_{agent}(a) = 1 - \frac{\sum_k c_k \mathbb{I}[v_k = a]}{\sum_k c_k}.$$

若报告缺少可解析标签，则不将其计入分母；若完全没有有效报告，则令  $Q_{agent} = 1$ ，避免将缺失信息误判为角色共识。对于不是  $\mathcal{A}_t$  中具体动作的决策类别，它不会为任何候选动作提供支持。该项衡量的是报告对动作标签的相对一致程度，并不等价于多个独立模型之间的统计分歧。最终的  $Q(a)$  同样是未校准的相对不确定性分数，而非概率。

### 3.6.5 约束选优与确定性回退

当前工程基线采用  $\tau_R = 0.35$ 、 $\tau_Q = 0.45$ 。满足以下条件的动作构成最终候选集合：

$$\mathcal{E}_t = \left\{ a \in \mathcal{A}_t^{safe} \mid R(a) \leq \tau_R \wedge Q(a) \leq \tau_Q \right\}.$$

若  $\mathcal{E}_t \neq \emptyset$ ，系统选择任务收益最大的动作；收益并列时依次比较更低风险、更低不确定性和动作名称，即

$$a_t^* = \underset{a \in \mathcal{E}_t}{\text{lexmin}}(-U_{\text{task}}(a), R(a), Q(a), \text{name}(a)),$$

从而保证相同输入产生相同输出。若  $\mathcal{E}_t = \emptyset$ ，则优先回退到 **safe\_stop**，其次为 **observe\_again**；若两者均不在  $\mathcal{A}_t$  中，当前实现返回空动作名称，该结果不能形成有效机器人动作。在本文假设 **safe\_stop** 始终可用时，保守回退始终具有定义。

最终输出包含每个动作的可行性、约束违反原因、收益分解、风险证据、不确定性证据、合格动作集合、模型原始建议、优化动作、二者是否一致以及决策来源，从而使动作选择过程可重放、可比较、可审计。阈值、权重、动作画像和暴露系数均被标记为 hand-configured、uncalibrated baseline；因此，本节给出的是可检验的确定性原型，而不是已经完成真实机器人数据校准的最优控制器。

### 3.7 Safety Verification and Decision Traceability

确定性优化器之后设置独立于语言模型的 Safety Guard，作为动作进入执行接口之前的最后一道检查。该模块不重新解释自然语言理由，也不依赖 Agent 的自报置信度，而是仅依据当前结构化场景、候选动作和固定硬阈值作出批准或覆盖决定。

#### 3.7.1 三阶段动作谱系

正常决策路径保留三个语义不同的动作：

| 动作                 | 来源                    | 含义                   |
|--------------------|-----------------------|----------------------|
| $a_t^{\text{LLM}}$ | Safety Decision Agent | 生成式模型基于审议证据给出的建议     |
| $a_t^*$            | 确定性约束优化器              | 在硬约束、风险和不确定性限制下选出的动作 |
| $a_t^{\text{app}}$ | Safety Guard          | 唯一可提交给未来执行适配器的批准动作   |

模型建议与优化动作的一致性记录为

$$I_{\text{agree}} = \mathbb{1}[a_t^{\text{LLM}} = a_t^*].$$

该变量用于统计语言模型与确定性优化器的一致率，并定位优化器纠正模型建议的案例。系统不会为了保持一致而优先选择  $a_t^{\text{LLM}}$ ；模型建议只通过 Agent 一致性项间接影响不确定性评分。执行决策还保存 **decision\_source** 和 **optimizer\_status**，以区分正常优化、无合格动作回退以及规则冲突旁路。

#### 3.7.2 Safety Guard 复核

令  $G$  表示 Safety Guard，则正常路径的最终动作满足

$$a_t^{\text{app}} = G(x_t, a_t^*).$$

Guard 再次检查障碍物紧急距离、观测置信度、剩余电量、通行总余量和动作授权。其阈值与第 3.6 节的硬约束保持一致：紧急障碍物距离不超过 0.30 m、观测置信度低于 0.50、电量不超过 10%、通行余量低于 0.10 m，或者动作不属于  $\mathcal{A}_t$ ，均会产生相应的 **hard\_rule\_violations**。该重复检查构成纵深防护：即使上游优化器的输出被错误构造或未来被其他模块替换，执行入口仍保留硬规则复核。

若不存在违反项，Guard 返回 **status=approved** 并保持候选动作不变。若存在违反项，则返回 **status=overridden** 并采用确定性回退：紧急障碍物、低电量、通行余量不足或未授权动作触发 **safe\_stop**；若唯一问题是观测置信度过低，则优先选择 **observe\_again**，不可用时再选择 **safe\_stop**。在本文动作空间假设下，这两种保守动作至少有一种可用。

L2 规则冲突形成一条更短的路径。此时三个 Agent 和第 3.6 节优化器均被绕过，冲突门控直接构造带 **decision\_source=deterministic\_rule\_conflict\_gate** 的保守决策，随后仍由同一个 Safety Guard 复核。因而，不论动作来自正常优化还是冲突回退，都不存在绕过最终执行检查的路径。

### 3.7.3 决策轨迹

系统将一次正常运行的决策轨迹组织为

$$\mathcal{T}_t = \left( \{\mathcal{B}_t^{(k)}\}_k, \mathcal{Q}_t, \rho_t^{rule}, d_t^{adv}, d_t^{cri}, d_t^{dec}, \Omega_t, a_t^{app}, \nu_t \right),$$

其中  $\rho_t^{rule}$  为 L2 规则协调结果， $\Omega_t$  为优化器对全部动作的评估记录， $\nu_t$  为各 Agent 的 Token 用量。具体输出包括角色化记忆卡及检索分解、命中规则及匹配原因、规则冲突状态、三份 Agent 报告与引用 ID、每个动作的硬约束拒绝原因、收益/风险/不确定性分解、合格动作集合、模型建议、优化动作、Guard 状态、覆盖原因与批准动作。规则冲突路径不产生 Agent 报告和优化评分，但会保留冲突规则、保守决策、人工复核要求及 Guard 结果。

当前命令行程序以分节 JSON 的形式输出上述轨迹，Agent 报告及其 Token 用量还可由基于输入摘要的缓存复用。完整轨迹目前并未自动写入事务化审计数据库；实验中需要通过输出重定向或上层运行器保存。因此，本节所称“可追溯”是指系统已生成稳定 ID、分项评分和动作来源链，而不是声称已经具备不可篡改的生产级日志基础设施。

### 3.7.4 验证边界

Safety Guard 是确定性运行时检查器，而非对连续机器人动力学的形式化安全证明。它基于单个决策时刻的场景快照，尚未处理观测到执行之间的状态变化、制动距离模型、定位误差传播或控制器动态响应。当前系统也尚未接入 ROS、Nav2 或具体机器人 SDK；**approved\_action** 只是未来执行适配器允许接收的动作。因此，在真实机器人部署前，仍需将 Guard 与实时传感器、底层碰撞检测、控制频率约束和硬件急停共同验证。

## 3.8 End-to-end Decision Algorithm

本节中的“端到端”表示从场景输入到批准动作输出的完整决策链路，而非端到端训练的神经网络。算法 1 将第 3.3 – 3.7 节连接为一个完整过程，并显式表示规则冲突旁路、Agent 报告验证、无合格动作回退和最终 Safety Guard。最终论文的 LaTeX 导言区需要引入 **algorithm** 和 **algpseudocode** 宏包。

**Algorithm 1** Overall Risk-aware Decision Procedure

---

Input: Scenario  $x_t$ , L0 store  $\mathcal{M}^{L0}$ , L2 store  $\mathcal{M}^{L2}$ , limits  $\tau_R, \tau_Q$   
Output: Approved action  $a_t^{\text{app}}$  or  $\perp$ , and decision trace  $\mathcal{T}_t$

```

1: for  $k \in \{\text{adv}, \text{cri}, \text{dec}\}$  do
2:    $\mathcal{B}_t^{(k)} \leftarrow \text{RetrieveRiskMemory}(x_t, \mathcal{M}^{L0}, k, K, B_k)$ 
3: end for
4:  $\mathcal{Q}_t \leftarrow \text{MatchRiskRules}(x_t, \mathcal{M}^{L2})$ 
5:  $\rho_t^{\text{rule}} \leftarrow \text{ResolveRuleConflicts}(\mathcal{Q}_t, \mathcal{A}_t)$ 
6: if  $\rho_t^{\text{rule}}.\text{status} = \text{conflict}$  then
7:    $d_t^{\text{conf}} \leftarrow \text{BuildConflictDecision}(\rho_t^{\text{rule}})$ 
8:    $a_t^{\text{app}} \leftarrow \text{SafetyGuard}(x_t, d_t^{\text{conf}}.\text{action})$ 
9:    $\mathcal{T}_t \leftarrow \text{BuildConflictTrace}(\mathcal{B}_t, \mathcal{Q}_t, \rho_t^{\text{rule}}, d_t^{\text{conf}}, a_t^{\text{app}})$ 
10:  return  $a_t^{\text{app}}, \mathcal{T}_t$ 
11: end if
12:  $d_t^{\text{adv}} \leftarrow \text{TaskAdvocate}(x_t, \mathcal{B}_t^{(\text{adv})}, \mathcal{Q}_t)$ 
13: if  $\neg \text{ValidReport}(d_t^{\text{adv}})$  then
14:   return  $\perp, \text{error}_{\text{adv}}$ 
15: end if
16:  $d_t^{\text{cri}} \leftarrow \text{RiskCritic}(x_t, \mathcal{B}_t^{(\text{cri})}, \mathcal{Q}_t)$ 
17: if  $\neg \text{ValidReport}(d_t^{\text{cri}})$  then
18:   return  $\perp, \text{error}_{\text{cri}}$ 
19: end if
20:  $d_t^{\text{dec}} \leftarrow \text{SafetyDecision}(x_t, \mathcal{B}_t^{(\text{dec})}, \mathcal{Q}_t, d_t^{\text{adv}}, d_t^{\text{cri}})$ 
21: if  $\neg \text{ValidReport}(d_t^{\text{dec}})$  then
22:   return  $\perp, \text{error}_{\text{dec}}$ 
23: end if
24:  $a_t^{\text{LLM}} \leftarrow d_t^{\text{dec}}.\text{action}$ 
25:  $\mathcal{A}_t^{\text{safe}} \leftarrow \text{FilterUnsafeActions}(x_t, \mathcal{Q}_t)$ 
26: for all  $a \in \mathcal{A}_t^{\text{safe}}$  do
27:    $u_a \leftarrow \text{TaskUtility}(a)$ 
28:    $r_a \leftarrow \text{ActionRisk}(x_t, a, \mathcal{B}_t^{(\text{dec})})$ 
29:    $q_a \leftarrow \text{ActionUncertainty}(x_t, a, \mathcal{B}_t^{(\text{dec})}, d_t^{\text{adv}}, d_t^{\text{cri}}, d_t^{\text{dec}})$ 
30: end for
31:  $\mathcal{E}_t \leftarrow \{a \in \mathcal{A}_t^{\text{safe}} \mid r_a \leq \tau_R \wedge q_a \leq \tau_Q\}$ 
32: if  $\mathcal{E}_t \neq \emptyset$  then
33:    $a_t^* \leftarrow \text{DeterministicBest}(\mathcal{E}_t, u, r, q)$ 
34: else
35:    $a_t^* \leftarrow \text{ConservativeFallback}(\mathcal{A}_t)$ 
36: end if
37:  $a_t^{\text{app}} \leftarrow \text{SafetyGuard}(x_t, a_t^*)$ 
38:  $\mathcal{T}_t \leftarrow \text{BuildDecisionTrace}(\mathcal{B}_t, \mathcal{Q}_t, \rho_t^{\text{rule}}, d_t^{\text{adv}}, d_t^{\text{cri}}, d_t^{\text{dec}}, a_t^{\text{LLM}}, a_t^*, a_t^{\text{app}})$ 
39: return  $a_t^{\text{app}}, \mathcal{T}_t$ 

```

---

其中 **DeterministicBest** 按  $(-u_a, r_a, q_a, \text{name}(a))$  的字典序选择动作, **ConservativeFallback** 按 **safe\_stop**, **observe\_again** 的顺序回退。**ValidReport** 概括第 3.5.4 节的 JSON、字段、范围、动作和引用检查; API 错误或验证失败同样返回  $\perp$ , 不产生可执行动作。当前命令行实现在失败时输出错误消息并以非零状态退出, 尚未构造与成功路径等量的结构化失败轨迹。

成功的 Agent 报告按照流程版本、场景、角色证据包和匹配规则的规范化 JSON 计算 SHA-256 摘要, 并存入摘要对应的缓存目录。缓存文件只在一次 Agent 调用完成并通过验证后写入,

可用于重复实验和节省 API 调用；但当前读取缓存时不会再次执行报告验证 或完整性校验，因此缓存目录应被视为受信任的本地实验状态，而非安全边界。确定性 检索、规则、优化与 Guard 模块本身不依赖外部模型服务，可在离线条件下测试。

### 3.9 Implementation and Current Scope

本研究实现了一个以 Python 为主的可执行原型，用于验证前述风险记忆、角色审议、确定性选优与安全复核能否形成闭合决策链。该实现强调模块边界和中间证据的可检查 性，而非端到端训练或直接控制真实机器人。

#### 3.9.1 Software Architecture

表 1 给出方法组件与实现文件之间的对应关系。三个语言模型角色位于 **agents/**，其余 核心组件均为确定性 Python 模块。**run\_three\_agents.py** 负责组装一次完整决策，但不负责执行机器人运动。

| 方法组件               | 主要实现                                                                            | 当前职责                                     |
|--------------------|---------------------------------------------------------------------------------|------------------------------------------|
| L0 经验、L1 风险卡与角色化检索 | <b>experience_store.py</b>                                                      | 加载完整经验，构造带来源信息的风险卡，并在 Token 预算下生成三类证据包   |
| L2 风险规则与冲突协调       | <b>risk_rule_store.py</b>                                                       | 校验和匹配规则，解释命中条件，并在建议不相容时触发保守回退            |
| 多角色风险审议            | <b>agents/advocate.py</b> 、 <b>agents/critic.py</b> 、 <b>agents/decision.py</b> | 构造角色提示、调用模型、校验结构化报告及其证据引用                |
| 确定性动作选择            | <b>decision_optimizer.py</b>                                                    | 执行硬约束过滤，计算收益、联合风险与多源不确定性，并确定性选优          |
| 最终安全复核             | <b>safety_guard.py</b>                                                          | 复查固定安全阈值，对不安全或未授权动作执行覆盖                  |
| 流程编排与缓存            | <b>run_three_agents.py</b>                                                      | 串联检索、规则、三角色、优化器和 Guard，并输出决策轨迹与 Token 用量 |

经验、规则与场景分别使用 JSON 文件表示，使场景输入、历史证据和规则库可以独立 替换。命令行辅助程序提供 L1 检索、L2 匹配、记忆运行对比和完整三角色流程入口，从而可以分别检查单个模块和整体链路。

#### 3.9.2 Model Interface and Reproducibility

当前三个角色通过 360 智脑的 OpenAI-compatible Chat Completions 接口调用 **z-ai/glm-5.1**。API 密钥、服务地址和模型名分别由 **ZHINAO\_API\_KEY**、**ZHINAO\_BASE\_URL** 和 **ZHINAO\_MODEL** 注入；密钥不写入源码或版本库。当前默认配置 使用温度 0.2、单次请求 120 s 超时和每个角色最多 5000 个生成 Token。角色化风险 证据包另设 1800 Token 的近似预算，以控制历史记忆进入上下文的长度。模型通信仅 承担结构化风险分析，记忆匹配、规则协调、动作评分和安全复核均不依赖外部模型服务。

为支持重复运行，系统以流程版本、场景、角色证据包和命中规则的规范化内容计算 SHA-256 缓存键。完全命中缓存时可以在不加载 API 密钥的情况下复现已有 Agent 报告；缓存未命中时才创建模型客户端。该机制减少重复调用造成的成本与随机差异，但缓存不是不可篡改的实验



记录, 读取时也尚未重新验证内容完整性。因此, 正式实验 仍应保存代码提交、配置、场景、原始响应和完整决策轨迹。

### 3.9.3 Verification and Simulation Support

当前主工程包含 62 项离线单元与集成测试。测试覆盖 L0 经验加载与校验、L1 分层 字段和来源信息、角色条件检索、风险感知评分、多样性及 Token 预算、L2 规则加载与 匹配、规则冲突处理、Agent 证据引用、动作硬约束、任务收益、场景与记忆联合风险、多源不确定性、确定性选优、冲突旁路以及 Safety Guard 覆盖行为。在线接口连通性由 `test_api.py` 单独检查, 不计入上述离线测试; 因此离线测试通过并不代表外部服务 可用, 也不构成真实机器人安全性的经验证明。

仓库还包含离散时钟、拓扑地图式的 2D 仿真环境, 可用于场景桥接、闭环步进、违规 记录和 HTML 回放。该仿真器不是连续几何或动力学仿真, 也不模拟定位误差、制动过程 和控制延迟。当前仿真中的 LLM planner 连接的是较早的“三角色审议—Safety Guard”路径, 尚未完整接入本文主流程新增的 L2 冲突门控与确定性动作优化器。因此, 现阶段 仿真结果只能验证接口与离散任务逻辑, 不能被表述为对完整方法或物理部署的验证。

### 3.9.4 Current Scope and Limitations

当前实现存在以下范围边界。第一, 系统尚未连接 ROS、Nav2 或具体机器人 SDK, `approved_action` 是结构化决策输出, 而非已发送给底层控制器的速度或轨迹命令。第二, L2 规则目前由人工整理, 尚未实现从新增 L0 经验中自动聚类、归纳、置信度更新 和失效规则淘汰; L1 风险卡也在检索时动态构造, 而非持久化的长期记忆实体。第三, 风险权重、不确定性权重、动作画像和阈值是手工配置的未校准基线。Critic 输出中的 `probability` 是语言模型的主观比较量, 不是事故频率估计, 也不作为优化器中的真实 发生概率。第四, 当前场景和历史经验规模较小且主要由人工设计, 尚不足以证明跨环境 泛化。第五, 完整轨迹目前依赖命令行输出或上层程序保存, 尚未接入事务化审计存储。

这些限制界定了本文原型的主张: 它实现并验证了一个可追踪、失效关闭的风险决策 软件流程, 但尚未证明连续动力学条件下的机器人安全性, 也尚未完成面向真实部署的 统计校准、系统集成和大规模实验。

### 3.9.5 Planned Evaluation

后续实验不涉及模型训练集, 而应将场景划分为规则与参数开发集、校准集和独立测试 集, 避免用测试场景反复调整阈值。主要指标包括任务成功率、碰撞或违规率、不安全 动作提议率、Guard 覆盖率、人工介入率、平均完成时间、API Token 消耗以及  $I_{agree}$  所定义的模型—优化器—致率。还应报告规则冲突频率、保守回退频率和 在不同观测噪声水平下的性能变化。

消融实验应分别移除 L1 风险卡、L2 风险规则、角色条件检索、Critic、确定性约束 优化器与 Safety Guard, 并设置无记忆、仅 L1、L1+L2 和完整系统等递增配置。参数 敏感性分析需要改变风险阈值、未知信息惩罚和角色检索权重。最终应在完整优化链已 接入仿真器后进行闭环对比, 再通过 ROS/Nav2 适配器、低速受控场地和硬件急停逐级 推进到真实机器人验证。