

3 方法

长期交互历史 → L0 原始经历 → L1 风险记忆卡 → L2 风险规则

↓ 角色条件化风险检索与证据预算

Task Advocate || Risk Critic → Safety Decision Agent → 确定性约束优化器 → Safety Guard → 执行

图 1: 方法概览。分层记忆压缩长期历史并保留来源链; 不同角色接收不同风险证据。语言模型不拥有直接执行权限。

3.1 系统概览

本文研究室内移动机器人在部分可观测环境中的高层语义动作选择。时刻 t 的规划输入记为

$$\mathcal{X}_t = (g_t, r_t, e_t, \mathcal{A}_t), \quad (1)$$

其中 g_t 为任务目标及进度, r_t 为机器人状态, e_t 为环境观测, $\mathcal{A}_t$ 为当前允许的有限动作集合。系统同时维护长期交互历史 $\mathcal{H}_t$, 目标是在避免将完整历史重复送入大语言模型的前提下, 利用与当前任务相关的风险经验生成可追溯决策。

整体流程如图 1 所示。历史执行首先被组织为 L0 原始风险经历, 并压缩为 L1 Risk Memory Card; 跨经历的稳定模式进一步形成 L2 Risk Rule。对于当前状态, 风险感知检索器分别为 Task Advocate、Risk Critic 和 Safety Decision Agent 构造角色条件化证据包。三个 Agent 仅产生结构化语义建议, 并通过经历 ID 与规则 ID 声明实际使用的证据。最终动作不由语言模型直接决定, 而由确定性约束优化器重新评估, 并经过独立 Safety Guard 复核。

令三个角色的报告集合为 $\mathcal{D}_t$, 匹配的 L2 规则为 $\mathcal{Q}_t$ 。优化器首先排除违反硬约束或 L2 禁止规则的动作, 再求解

$$a_t^* = \arg \max_{a \in \mathcal{F}_t} U(a), \quad \text{s.t. } R(a) \leq \rho, Z(a) \leq \eta, \quad (2)$$

其中 $\mathcal{F}_t \subseteq \mathcal{A}_t$ 为可行动作集合, U 为任务收益, R 联合当前场景与历史记忆估计相对风险, Z 综合观测置信度、记忆覆盖和 Agent 分歧估计相对不确定性。这里的 R 与 Z 是可解释的相对分数, 而非经过校准的概率。若 L2 规则冲突、Agent 输出校验失败、不存在合格动作或 Safety Guard 检测到硬约束违反, 系统执行 **safe_stop**、**observe_again** 或请求人工复核, 实现失效关闭。

3.2 L0-L1-L2 分层风险记忆

分层记忆同时解决三个问题: 以统一结构表达具身风险经历, 在有限上下文内压缩长期历史, 以及保留抽象规则到原始案例的证据链。记忆图记为

$$\mathcal{G}_t = (\mathcal{E}_t, \mathcal{M}_t, \mathcal{Q}_t, \mathcal{L}_t), \quad (3)$$

其中 $\mathcal{E}_t$ 、 $\mathcal{M}_t$ 和 $\mathcal{Q}_t$ 分别表示 L0、L1 和 L2 节点, $\mathcal{L}_t$ 保存稳定 ID 之间的来源链接。

3.2.1 L0: 具身风险经历表示

L0 保存能够支持事后核查和重新抽象的完整交互证据。第 i 条经历写为

$$E_i = (G_i, S_i, A_i, O_i, F_i, K_i, D_i, P_i), \quad (4)$$

其中 G_i 为任务目标, S_i 统一包含机器人与环境状态, A_i 为执行动作, O_i 为动作结果, F_i 为失败原因, K_i 为风险类型与严重度, D_i 为当时的决策, P_i 为轨迹来源及时

间信息。该表示将“机器人在何种任务和环境下采取何种动作、产生何种后果以及风险为何发生”绑定在同一记录中, 避免只保存孤立的成功率或自然语言教训。

每条 L0 经历具有不可变的 **experience_id**, 并可链接传感日志、控制记录或人工标注。经历校验至少检查必需字段、结果状态、严重度范围和 ID 唯一性。原始信息不直接全部进入 Agent 上下文, 而作为后续压缩与审计的证据底座。

3.2.2 L1: 风险记忆卡

L1 通过确定性压缩映射 C 将完整经历转化为紧凑风险记忆卡:

$$M_i = C(E_i) = (T_i, H_i, A_i, O_i, F_i, B_i, Q_i, P_i), \quad (5)$$

其中 T_i 为触发条件, H_i 为危险类型与严重度, B_i 包含缓解措施和停止条件, Q_i 包含支持次数、可靠性及最近验证时间, P_i 保留来源。触发条件只保留对风险判别必要的状态, 例如通行余量、障碍物距离、观测置信度和电量, 而删除冗长轨迹中的重复描述。

每张卡具有稳定的 **memory_id**, 并显式保存其 **experience_id** 和来源片段。因而, 压缩不会切断证据链: Agent 可以使用短卡片进行推理, 审计者仍可沿 $M_i \rightarrow E_i$ 回查原始轨迹。卡片还保存检索得分分解和匹配原因, 使“为何该经历进入上下文”可被复现。

3.2.3 L2: 风险规则与认知演化

L2 将多个相关 L1 卡片中的稳定风险模式表达为条件规则

$$Q_j = (C_j, K_j, A_j^+, A_j^-, B_j, N_j, c_j, z_j), \quad (6)$$

其中 C_j 为触发条件, K_j 为风险类型, A_j^+ 与 A_j^- 分别为建议和禁止动作, B_j 为缓解措施, N_j 为来源记忆 ID 集合, c_j 为置信度, $z_j \in \{\text{candidate, active, retired}\}$ 为生命周期状态。规则仅在触发条件满足时参与当前决策; 其来源集合提供 $Q_j \rightarrow M_i \rightarrow E_i$ 的完整追溯路径。

长期交互通过增量证据推动风险认知演化。新轨迹首先形成 L0 经历, 相似经历更新 L1 的支持统计与可靠性; 反复出现且得到足够支持的模式形成或强化候选 L2 规则。与既有规则矛盾的新证据可降低其置信度、修订触发范围或使其停用。该过程使安全边界由静态提示转化为随经验证据更新的知识边界, 同时避免一次偶然失败直接生成强规则。

运行时仅匹配 **active** 规则。若多条命中规则仍存在共同且未被禁止的建议动作, 系统保留该交集; 若不存在共同安全建议, 确定性冲突闸门不调用 LLM 仲裁, 而是停止并请求人工复核。该设计将经验规则的不一致显式暴露出来, 防止模型按语言置信度隐式选择互斥规则。

为使长期更新可复现, 每个风险模式维护统计量 $n_j = (n_j^+, n_j^-, n_j^0)$, 分别表示缓解成功、风险失败和人工中止的支持次数。缺少显式质量标注时, 规则可靠性可由带平滑的证据估计给出:

$$c_j = \frac{n_j^+ + n_j^- + \alpha}{n_j^+ + n_j^- + n_j^0 + \alpha + \beta}, \quad (7)$$

其中 $\alpha, \beta > 0$ 防止少量样本产生极端置信度。候选规则只有在来源数、跨场景一致性和最低置信度同时满足时才转为 active；持续冲突、长期未验证或被反例否定的规则降为 candidate 或 retired。所有状态变化创建新版本并保留旧版本及触发更新的来源 ID，使安全边界的变化本身也可审计。

该演化过程区分“风险发生的证据”和“缓解有效的证据”。失败案例用于识别禁止动作及停止条件，成功案例用于验证缓解措施不会导致永久停止。只有同时覆盖风险与缓解的规则才能扩展到相似场景，从而降低系统因累积失败记忆而不断趋于保守的风险。

3.3 角色条件化的风险感知检索

给定当前输入 $\mathcal{X}_t$ 和角色 $r \in \{\text{adv}, \text{crit}, \text{dec}\}$ ，检索器首先计算 L0 经历与当前场景的透明相似度。比较因素包括机器人类型、障碍物状态、通行余量、障碍物距离、观测置信度和任务目标。仅保留具有正相似度的候选，再对每条候选计算

$$s_i^{(r)} = \sum_{k \in \mathcal{K}} w_k^{(r)} \phi_{ik}, \quad \mathcal{K} = \{\text{sim}, \text{sev}, \text{rel}, \text{rec}, \text{fit}\}, \quad (8)$$

其中 $\phi_{ik} \in [0, 1]$ 分别表示场景相似度、风险严重度、证据可靠性、时效性和角色适配度； $w_k^{(r)}$ 为角色相关权重且和为 1。可靠性优先使用显式质量评分；当只有成功/失败统计时，使用带平滑的后验均值，避免单次观测产生过度确定性。时效性使用随验证间隔衰减的函数。

角色条件化体现在 $w_k^{(r)}$ 与 fit 的共同作用。Advocate 强调可迁移的成功经历和有效缓解措施；Critic 提高失败、高严重度和停止条件证据的优先级；Decision 使用较平衡的正反案例以支持最终裁决。因此，三个角色并非在同一证据包上仅更换提示词，而是在推理前即获得不同的经验分布。

当前原型采用如下可审计基线权重，分量顺序为 (sim, sev, rel, rec, fit)：

$$w^{(\text{adv})} = (.35, .05, .20, .05, .35), \quad (9)$$

$$w^{(\text{crit})} = (.30, .25, .15, .05, .25), \quad (10)$$

$$w^{(\text{dec})} = (.35, .20, .20, .10, .15). \quad (11)$$

这些权重用于定义透明、可重复的工程基线，而非声称已经从数据中学习得到；后续实验通过消融和敏感性分析检验角色项、严重度项及可靠性项的独立作用。

为避免 Top-k 被重复案例占满，系统采用贪心多样性选择。在已选集合 S 下，下一条记忆为

$$i^* = \arg \max_{i \notin S} \left[s_i^{(r)} - \lambda \max_{j \in S} d(i, j) \right], \quad (12)$$

其中 $d(i, j)$ 根据相同风险类型、结果状态和教训计算冗余度， λ 控制相关性与多样性的权衡。候选随后被转换为 L1 卡片，并在预算 B_r 下依次装入角色证据包：

$$\sum_{M_i \in \mathcal{B}_r} \hat{\tau}(M_i) \leq B_r, \quad (13)$$

其中 $\hat{\tau}$ 是针对中英文 JSON 的保守 Token 估计。超过预算的卡片被跳过，从而使历史规模增长时 Agent 输入仍保持有界。

最终证据包包含角色、检索版本、预算使用量、L1 卡片、逐项得分分解、匹配原因和来源 ID；匹配的 L2 规则作为跨经历证据单独附加。Agent 输出必须在 cited_experience_ids 与 cited_rule_ids 中声明实际使用的证据，系统拒绝输入包中不存在的 ID。该闭环同时回答了三个审计问题：系统检索了什么、为何检索，以及哪些证据真正影响了建议。

完整检索过程可概括为算法 1。设经验库大小为 N ，每个角色最多选取 K 张卡片。透明特征计算为 $O(N)$ ，贪心去冗余为 $O(NK)$ ；由于 K 由提示预算固定，在线检索开销随历史规模近似线性增长。三个角色可共享场景特征计算，但分别完成角色精排和预算装包。

算法 1：角色条件化风险检索

输入：当前状态 $\mathcal{X}_t$ ，角色 r ，L0 库 $\mathcal{E}$ ，预算 B_r ，上限 K 。

- 1) 校验角色与输入结构；
- 2) 计算每条经历的透明场景相似度；
- 3) 计算严重度、可靠性、时效性和角色适配度；
- 4) 使用 $w^{(r)}$ 计算角色得分 $s_i^{(r)}$ ；
- 5) 以式 (8) 的冗余惩罚贪心选择候选；
- 6) 将候选确定性压缩为 L1 卡片；
- 7) 按式 (9) 装入 Token 预算并附加匹配 L2 规则；
- 8) 返回含得分分解、匹配原因和来源 ID 的证据包。

综上，分层风险记忆控制长期历史的上下文规模并保留抽象来源，角色条件化检索则把不同风险证据分配给不同审议职责。二者共同为后续确定性动作选择提供可追溯的语义依据，而不将执行权限交给语言模型。