

3 方法

核心机制一：可追溯风险抽象： L0 原始经历 | L1 风险记忆卡 | L2 风险规则
 核心机制二：面向职责的证据分配： Task Advocate | Risk Critic | Safety Decision Agent
 执行权限边界： 结构化建议 | 确定性约束优化器 | Safety Guard

图 1: 方法概览。两个耦合机制将交互历史转化为可追溯的风险抽象，并按决策职责分配证据；确定性模块保留执行权限。

3.1 系统概览

本文提出一种风险经验驱动的多角色框架，其核心创新是将可追溯风险抽象与面向职责的证据分配相互耦合。给定交互历史 $\mathcal{H}_t$ ，第一项机制将完整交互转化为紧凑的单案例卡片和跨案例规则，同时保留支撑每层抽象的证据。给定当前规划输入 $\mathcal{X}_t = (g_t, r_t, e_t, \mathcal{A}_t)$ ，第二项机制针对不同决策职责选择不同的证据包。因此，长期经验首先按风险结构压缩，再根据其在协商中的用途选择性呈现。

Task Advocate、Risk Critic 和 Safety Decision Agent 分别解释所分配的证据，并输出包含证据 ID 的结构化建议。确定性约束优化器随后从允许动作集 $\mathcal{A}_t$ 中选择语义动作，独立 Safety Guard 在执行前对其进行验证。因此，Agent 提供由证据支撑的语义判断，但不拥有可执行控制权限。第 3.2 节定义可追溯抽象机制，第 3.3 节定义面向职责的证据分配及其决策集成。

3.2 可追溯的分层风险记忆

第一项机制构造了具有明确决策功能的分层记忆：L0 经历集 $\mathcal{E}_t$ 保留完整交互，L1 卡片集 $\mathcal{M}_t$ 显式提取单个案例的风险结构，L2 规则集 $\mathcal{Q}_t$ 编码由多个案例共同支持的模式。其关键性质是可追溯抽象，即每次压缩均通过稳定 ID 保留与输入证据的关联。这些关联用于计算规则支持度、校验决策引用，并在新证据与规则冲突时定位受影响的案例。因此，该层次结构既压缩决策上下文，又使每层抽象能够由经验验证和更新。

3.2.1 L0: 具身风险经历表示

L0 将一次交互表示为经历 E_i ，记录任务与场景条件、动作 A_i 、结果 O_i 、失败原因、风险类型、严重度 $\sigma_i \in \{1, \dots, 5\}$ 和轨迹来源。不可变的 `experience_id` 将其链接至传感日志、控制记录或人工标注。

为在统一的风险尺度下比较不同观测，本文将 E_i 编码为风险状态 $z_i = [1 - \bar{c}_i, 1 - \bar{d}_i, 1 - p_i, 1 - b_i, h_i]$ 。其中， $\bar{c}_i$ 和 $\bar{d}_i$ 是归一化通行余量与障碍物距离， p_i 是观测置信度， b_i 是电量比例， h_i 包含机器人、障碍和任务等离散条件。取补值后，较大的前四项均表示更强的风险因素；完整轨迹保留在 L0 中供审计。

3.2.2 L1: 风险记忆卡

L1 将每条经历压缩为风险记忆卡。归一化严重度 $\sigma_i/5$ 表示后果强度；结果权重 $\omega(O_i)$ 对 failure、aborted 和 success 分别取 1、0.8 和 0.05；可靠性 $\gamma_i \in [0, 1]$ 用于降低低质量记录的影响。三者乘积 $q_i = (\sigma_i/5)\omega(O_i)\gamma_i$ 是相对证据分数，而非碰撞概率。令 F_i 表示失败原因， B_i 表示缓解措施与停止条件， P_i 表示由 memory ID、experience ID 和来源片段组成的来源记录。

将 z_i 与 q_i 逐步代入压缩映射，可得 L1 卡片：

$$\begin{aligned} M_i &= C(E_i) = \text{Pack}(z_i, A_i, O_i, F_i, B_i, q_i, P_i) \\ &= \text{Pack}([1 - \bar{c}_i, 1 - \bar{d}_i, 1 - p_i, 1 - b_i, h_i], \\ &\quad A_i, O_i, F_i, B_i, \frac{\sigma_i}{5}\omega(O_i)\gamma_i, P_i). \end{aligned} \quad (1)$$

式 (1) 表明，L0 经历的风险状态、结果证据和来源记录共同构成可追溯的 L1 卡片。

3.2.3 L2: 风险规则聚合与更新

L2 将风险状态、风险类型和动作语义相近的卡片组成模式集合 $\mathcal{I}_j$ 。聚合映射 $\mathcal{A}$ 根据其中的触发条件、建议与禁止动作、缓解措施和来源 ID 生成规则 Q_j 。令 n_j^+ 、 n_j^- 和 n_j^0 分别表示缓解成功、风险失败和未决中止次数，并以 θ_j 表示新观测为规则 Q_j 提供明确证据的概率。采用 Beta(α, β) 先验，其后验均值 c_j 为

$$\begin{aligned} (Q_j, c_j) &= \mathcal{A}(\{M_i\}_{i \in \mathcal{I}_j}), \\ c_j &= \mathbb{E}[\theta_j | \mathcal{I}_j] = \frac{n_j^+ + n_j^- + \alpha}{n_j^+ + n_j^- + n_j^0 + \alpha + \beta}. \end{aligned} \quad (2)$$

这里 c_j 衡量明确经验支持的程度，而非风险发生概率。 Q_j 的来源集合决定 c_j 中的计数，并在规则转为 active 前接受一致性检查。当新的 L0 结果支持或反驳该规则时，来源 ID 用于定位相关卡片，进而重新计算支持度、修订触发条件或将规则转为 retired。因此，版本化的 $Q_j \rightarrow M_i \rightarrow E_i$ 链参与规则验证与维护，而非仅作为附加元数据保存。

运行时，规则闸门仅允许所有命中 active 规则共同建议且均未禁止的动作；若交集为空，则停止执行并请求人工复核。

3.3 角色条件化的风险证据检索

第二项机制以决策职责为条件分配证据。在相同状态和记忆下，Advocate 优先获取任务推进与成功缓解证据，Critic 优先获取失败案例与停止条件，Decision Agent 优先获取用于权衡任务收益和风险的证据。其关键不只是设置多个角色，而是将角色条件置于检索过程内部，使不同职责在协商前即获得不同证据。给定 $\mathcal{X}_t$ ，每张卡片产生特征向量 $\phi_i = [\text{sim}, \text{sev}, \text{rel}, \text{rec}, \text{fit}] \in [0, 1]^5$ ，分别表示情境相似度、严重度、可靠性、时效性和角色适配度。角色权重 $w^{(r)}$ 将这些公共特征转化为面向职责的相关性。

对于角色 r ， $\mathcal{B}$ 表示候选证据包， K 限制卡片数量， B_r 是 Token 预算。冗余度 $d(i, j)$ 用于减少风险类型、结果和缓解措施重复的案例， $\hat{\tau}(M_i)$ 估计卡片 M_i 的 Token 开销， λ 控制冗余惩罚。检索据此选择

$$\begin{aligned} \mathcal{B}_r^* &= \arg \max_{\mathcal{B} \subseteq \mathcal{M}_t} \sum_{M_i \in \mathcal{B}} (w^{(r)})^\top \phi_i - \lambda \sum_{\substack{M_i, M_j \in \mathcal{B} \\ i < j}} d(i, j) \\ \text{s.t. } |\mathcal{B}| &\leq K, \quad \sum_{M_i \in \mathcal{B}} \hat{\tau}(M_i) \leq B_r. \end{aligned} \quad (3)$$

对于 (sim, sev, rel, rec, fit), 本文取

$$\begin{aligned} w^{(\text{adv})} &= (0.35, 0.05, 0.20, 0.05, 0.35), \\ w^{(\text{crit})} &= (0.30, 0.25, 0.15, 0.05, 0.25), \\ w^{(\text{dec})} &= (0.35, 0.20, 0.20, 0.10, 0.15). \end{aligned}$$

算法 1 以贪心边际增益近似求解式 (3), 实验部分评估分角色权重的作用。

每个证据包记录角色与检索版本、选中的 L1 卡片和命中的 L2 规则、得分、匹配原因、预算用量及来源 ID。命中规则约束可行动作, 其来源集合则记录该约束由哪些案例支持。Agent 通过 **cited_experience_ids** 和 **cited_rule_ids** 声明所用证据, 框架拒绝证据包外的 ID, 并将合法引用与优化器及 Safety Guard 输出共同保存, 从而把动作的执行或拒绝关联到相应规则及其来源案例。

令 $\mathcal{D}_t$ 表示三个角色的报告, $\mathcal{F}_t$ 表示满足硬约束和 L2 禁止规则的动作集合。对于动作 a , $U(a)$ 是任务效用, $R(a \mid \mathcal{B}_{\text{dec}}^*)$ 是场景与记忆的联合风险, $Z(a \mid \mathcal{D}_t, \mathcal{B}_{\text{dec}}^*)$ 综合观测置信度、记忆覆盖和角色分歧。

阈值 ρ 和 η 分别约束风险和不确定性。

确定性优化器选择

$$\begin{aligned} a_t^* &= \arg \max_{a \in \mathcal{F}_t} U(a), \\ R(a \mid \mathcal{B}_{\text{dec}}^*) &\leq \rho, \\ Z(a \mid \mathcal{D}_t, \mathcal{B}_{\text{dec}}^*) &\leq \eta. \end{aligned} \tag{4}$$

规则冲突、输出无效、可行集为空或 Safety Guard 拒绝动作时, 框架触发 **safe_stop**、**observe_again** 或人工复核。该确定性边界为上述两项记忆机制提供执行保障, 防止语义建议绕过动作约束。

算法 1: 角色条件化风险检索

输入: 状态 $\mathcal{X}_t$, 角色集 $\mathcal{R}$, L1 卡片集 $\mathcal{M}$, active L2 规则集 $\mathcal{Q}$, 预算 $\{B_r\}$, 上限 K
 输出: 分角色证据包 $\{\mathcal{B}_r\}_{r \in \mathcal{R}}$
 1: 校验 $\mathcal{X}_t$, $\mathcal{R}$, $\mathcal{M}$ 与 $\mathcal{Q}$
 2: 对 每个角色 $r \in \mathcal{R}$ 执行
 3: 计算所有 ϕ_i ; 初始化候选集 $\mathcal{C}_r$ 与 $\mathcal{B}_r \leftarrow \emptyset$
 4: 当 $\mathcal{C}_r \neq \emptyset$ 且 $|\mathcal{B}_r| < K$ 执行
 5: 按式 (3) 的边际增益选取 M_{i^*}
 6: 从 $\mathcal{C}_r$ 删除 M_{i^*}
 7: 若 $\hat{\tau}(\mathcal{B}_r) + \hat{\tau}(M_{i^*}) \leq B_r$ 则
 8: $\mathcal{B}_r \leftarrow \mathcal{B}_r \cup \{M_{i^*}\}$
 9: 条件结束
 10: 循环结束
 11: 向 $\mathcal{B}_r$ 附加命中的 active L2 规则、得分、原因和来源 ID
 12: 循环结束
 13: return $\{\mathcal{B}_r\}_{r \in \mathcal{R}}$