

3 方法




图 1: 方法概览。分层记忆压缩长期历史并保留来源链; 不同角色接收不同风险证据; 确定性模块保留执行权限。

3.1 系统概览

本文研究室内移动机器人在部分可观测环境中的高层语义动作选择。时刻 t 的规划输入记为

$$\mathcal{X}_t = (g_t, r_t, e_t, \mathcal{A}_t), \quad (1)$$

其中 g_t 为任务目标及进度, r_t 为机器人状态, e_t 为环境观测, $\mathcal{A}_t$ 为当前允许的有限动作集合。系统维护长期交互历史 $\mathcal{H}_t$, 并在有界模型上下文内提供与当前任务相关且可追溯的风险证据。

图 1 给出整体流程。系统将执行记录存为 L0 原始经历, 将其压缩为 L1 Risk Memory Card, 并将跨经历的稳定模式抽象为 L2 Risk Rule。检索器为 Task Advocate、Risk Critic 和 Safety Decision Agent 分别构造证据包。三个 Agent 输出结构化建议及其引用的经历和规则 ID。确定性约束优化器据此选择动作, 再由独立 Safety Guard 复核。

令三个角色的报告集合为 $\mathcal{D}_t$, 匹配的 L2 规则为 $\mathcal{Q}_t$ 。优化器首先排除违反硬约束或 L2 禁止规则的动作, 再求解

$$a_t^* = \arg \max_{a \in \mathcal{F}_t} U(a), \quad \text{s.t. } R(a) \leq \rho, Z(a) \leq \eta, \quad (2)$$

其中 $\mathcal{F}_t \subseteq \mathcal{A}_t$ 为可行动作集合, U 为任务收益, R 为场景与记忆联合风险, Z 为观测置信度、记忆覆盖和 Agent 分歧构成的不确定性。 R 与 Z 均为相对分数, 而非校准概率。L2 规则冲突、Agent 输出无效、可行集为空或 Safety Guard 拒绝动作时, 系统执行 **safe_stop**、**observe_again** 或请求人工复核。

3.2 L0-L1-L2 分层风险记忆

分层记忆统一表示风险经历、压缩长期历史, 并保留抽象规则到原始案例的证据链。记忆图记为

$$\mathcal{G}_t = (\mathcal{E}_t, \mathcal{M}_t, \mathcal{Q}_t, \mathcal{L}_t), \quad (3)$$

其中 $\mathcal{E}_t$ 、 $\mathcal{M}_t$ 和 $\mathcal{Q}_t$ 分别表示 L0、L1 和 L2 节点, $\mathcal{L}_t$ 保存稳定 ID 之间的来源链接。

3.2.1 L0: 具身风险经历表示

L0 保存能够支持事后核查和重新抽象的完整交互证据。第 i 条经历写为

$$E_i = (G_i, S_i, A_i, O_i, F_i, K_i, D_i, P_i), \quad (4)$$

其中 G_i 为任务目标, S_i 为机器人与环境状态, A_i 为执行动作, O_i 为动作结果, F_i 为失败原因, K_i 为风险类型与严重度, D_i 为决策记录, P_i 为轨迹来源及时间。该结构完整关联任务、状态、动作、结果和风险原因, 以支持案例重建。

每条 L0 经历具有不可变的 **experience_id**, 并可链接传感日志、控制记录或人工标注。写入时校验必需字段、结果状态、严重度范围和 ID 唯一性。Agent 接收压缩后的 L1 表示, L0 则保存用于压缩与审计的原始证据。

3.2.2 L1: 风险记忆卡

L1 通过确定性压缩映射 C 将完整经历转化为紧凑风险记忆卡:

$$M_i = C(E_i) = (T_i, H_i, A_i, O_i, F_i, B_i, Q_i, P_i), \quad (5)$$

其中 T_i 为触发条件, H_i 为危险类型与严重度, B_i 为缓解措施和停止条件, Q_i 为支持次数、可靠性及最近验证时间, P_i 为来源信息。 T_i 仅保留通行余量、障碍物距离、观测置信度和电量等风险相关状态。

每张卡具有稳定的 **memory_id**, 并保存其 **experience_id** 和来源片段。Agent 使用卡片推理, 审计者可沿 $M_i \rightarrow E_i$ 回查原始轨迹。卡片同时记录检索得分分解和匹配原因, 使检索结果可复现。

3.2.3 L2: 风险规则与认知演化

L2 将多个相关 L1 卡片中的稳定风险模式表达为条件规则

$$Q_j = (C_j, K_j, A_j^+, A_j^-, B_j, N_j, c_j, z_j), \quad (6)$$

其中 C_j 为触发条件, K_j 为风险类型, A_j^+ 与 A_j^- 分别为建议和禁止动作, B_j 为缓解措施, N_j 为来源记忆 ID 集合, c_j 为置信度, $z_j \in \{\text{candidate}, \text{active}, \text{retired}\}$ 为生命周期状态。规则仅在触发条件满足时参与当前决策; 其来源集合提供 $Q_j \rightarrow M_i \rightarrow E_i$ 的完整追溯路径。

新轨迹形成 L0 经历, 相似经历更新 L1 的支持统计与可靠性, 重复且充分支持的模式形成或强化候选 L2 规则。矛盾证据降低规则置信度、修订触发范围或使规则停用。最低支持阈值避免单次失败直接生成强规则。

运行时仅匹配 **active** 规则。若命中规则存在共同且未被禁止的建议动作, 系统保留其交集; 否则, 确定性冲突闸门停止执行并请求人工复核。

为使长期更新可复现, 每个风险模式维护统计量 $n_j = (n_j^+, n_j^-, n_j^0)$, 分别表示缓解成功、风险失败和人工中止的支持次数。缺少显式质量标注时, 规则可靠性可由带平滑的证据估计给出:

$$c_j = \frac{n_j^+ + n_j^- + \alpha}{n_j^+ + n_j^- + n_j^0 + \alpha + \beta}, \quad (7)$$

其中 $\alpha, \beta > 0$ 抑制小样本产生的极端置信度。候选规则在满足最低来源数、跨场景一致性和置信度阈值后转为 **active**; 持续冲突、长期未验证或被反例否定时降为 **candidate** 或 **retired**。每次状态变化均创建新版本, 并保留旧版本和触发更新的来源 ID。

失败案例用于识别禁止动作和停止条件, 成功案例用于验证缓解措施。规则仅在两类证据均被覆盖时扩展到相似场景, 以限制失败记忆累积导致的过度保守。

3.3 角色条件化的风险感知检索

给定输入 $\mathcal{X}_t$ 和角色 $r \in \{\text{adv}, \text{crit}, \text{dec}\}$ ，检索器根据机器人类型、障碍物状态、通行余量、障碍物距离、观测置信度和任务目标计算 L0 经历的确定性场景相似度。正相似度候选的角色得分

$$s_i^{(r)} = \sum_{k \in \mathcal{K}} w_k^{(r)} \phi_{ik}, \quad \mathcal{K} = \{\text{sim}, \text{sev}, \text{rel}, \text{rec}, \text{fit}\}, \quad (8)$$

其中 $\phi_{ik} \in [0, 1]$ 表示场景相似度、风险严重度、证据可靠性、时效性或角色适配度，角色权重 $w_k^{(r)}$ 之和为 1。可靠性优先采用显式质量评分，否则采用平滑后验均值；时效性随验证间隔衰减。

角色条件化由 $w_k^{(r)}$ 与 fit 共同实现。Advocate 强调成功经历和有效缓解措施，Critic 强调失败、高严重度风险和停止条件，Decision 平衡正反案例。因此，三个角色在推理前获得不同的经验分布。

当前原型采用如下可审计基线权重，分量顺序为 (sim, sev, rel, rec, fit)：

$$w^{(\text{adv})} = (.35, .05, .20, .05, .35), \quad (9)$$

$$w^{(\text{crit})} = (.30, .25, .15, .05, .25), \quad (10)$$

$$w^{(\text{dec})} = (.35, .20, .20, .10, .15). \quad (11)$$

这些手工设定的权重构成可复现基线。消融和敏感性分析分别检验角色适配度、严重度和可靠性的作用。

为避免 Top- k 被重复案例占满，系统采用贪心多样性选择。在已选集合 S 下，下一条记忆为

$$i^* = \arg \max_{i \notin S} \left[s_i^{(r)} - \lambda \max_{j \in S} d(i, j) \right], \quad (12)$$

其中 $d(i, j)$ 根据风险类型、结果状态和缓解措施计算冗余度， λ 控制相关性与多样性的权衡。候选被转换为 L1

卡片，并装入预算为 B_r 的证据包：

$$\sum_{M_i \in \mathcal{B}_r} \hat{\tau}(M_i) \leq B_r, \quad (13)$$

其中 $\hat{\tau}$ 是针对中英文 JSON 的保守 Token 估计。超过预算的卡片被跳过，从而使历史规模增长时 Agent 输入仍保持有界。

证据包包含角色、检索版本、预算使用量、L1 卡片、得分分解、匹配原因和来源 ID，并单独附加命中的 L2 规则。Agent 必须在 `cited_experience_ids` 与 `cited_rule_ids` 中声明所用证据；系统拒绝输入包中不存在的 ID。该记录支持审计检索内容、检索原因和实际引用。

算法 1 概括检索过程。对大小为 N 的经验库，每个角色最多选取 K 张卡片；特征计算为 $O(N)$ ，贪心去冗余为 $O(NK)$ 。由于 K 由上下文预算固定，在线开销随 N 近似线性增长。三个角色共享场景特征，但分别排序和装包。

算法 1：角色条件化风险检索

输入：当前状态 $\mathcal{X}_t$ ，角色 r ，L0 库 $\mathcal{E}$ ，预算 B_r ，上限 K 。

- 1) 校验角色与输入结构；
- 2) 计算每条经历的透明场景相似度；
- 3) 计算严重度、可靠性、时效性和角色适配度；
- 4) 使用 $w^{(r)}$ 计算角色得分 $s_i^{(r)}$ ；
- 5) 以式 (12) 的冗余惩罚贪心选择候选；
- 6) 将候选确定性压缩为 L1 卡片；
- 7) 按式 (13) 装入 Token 预算并附加匹配 L2 规则；
- 8) 返回含得分分解、匹配原因和来源 ID 的证据包。